

Identificar el sexo de abulones mediante regresión logística.

Yael Charles Marin

A01711111

Tecnológico de Monterrey Campús Querétaro

Inteligencia artificial avanzada para la ciencia de datos

Grupo 601

Abstract—Este trabajo trata sobre la clasificación del sexo de abulones utilizando las características físicas de longitud, diámetro, altura, diferentes medidas de peso y número de anillos. Se realizó un análisis exploratorio de datos, transformación, análisis de correlación, desarrollo de modelos y evaluación de desempeño. Durante el preprocesamiento se identificaron y eliminaron observaciones extremas o físicamente inconsistentes, reduciendo el conjunto original de 4,177 a 4,131 registros. El análisis de correlación mostró relaciones fuertes entre las variables físicas, mientras que la clase Infant presentó un comportamiento más notorio en comparación con las clases Male y Female. Posteriormente, se implementó manualmente un modelo de regresión logística utilizando la estrategia One-vs-All, donde se obtuvo exactitudes de 53.82%, 53.63% y 52.01% en los conjuntos de entrenamiento, validación y prueba, respectivamente. También se evaluó un modelo Random Forest implementado con scikit-learn, el cual alcanzó 100% de exactitud en entrenamiento y aproximadamente 56% en validación y prueba. Ambos modelos mostraron una mayor capacidad para identificar la clase Infant, mientras que distinguir entre Male y Female representó la principal dificultad de clasificación. Esto sugiere que las características físicas disponibles permiten identificar con mayor claridad los abulones en etapas tempranas de su desarrollo, pero presentan una capacidad limitada para separar de forma efectiva a los abulones machos y hembras.

Index Terms—Abulón, clasificación, regresión logística, sigmoide, entropía cruzada, gradiente descendiente, algoritmo manual, random forest, evaluación de resultados.

I. INTRODUCTION

Los abulones son moluscos gasterópodos marinos pertenecientes al género *Haliotis*, caracterizados por poseer una sola concha de forma aplanada y un cuerpo blando con un pie muscular que les permite adherirse a superficies rocosas. Su carne es considerada un producto de alto valor comercial y alimenticio en lugares como China o Japón, aunque también en gastronomías como la Estadounidense y Mexicana. [1]

La identificación del sexo de los abulones es relevante principalmente para el manejo reproductivo y la crianza selectiva en sistemas de cultivo. Los abulones presentan sexos separados, es decir, cada individuo es macho o hembra, y su reproducción ocurre mediante la liberación de espermatozoides y óvulos al agua. Sin embargo, determinar el sexo puede ser complicado en individuos jóvenes o que todavía no han desarrollado suficientemente sus órganos reproductores. Esta dificultad representa una oportunidad para utilizar técnicas de

Machine Learning que permitan estimar el sexo a partir de características físicas fácilmente medibles del abulón. [2]

Este proyecto tiene como objetivo utilizar atributos físicos de los abulones, como sus medidas corporales y peso, para predecir su sexo mediante técnicas de clasificación implementadas en Python. Para ello, se desarrollará inicialmente un modelo de regresión logística sin utilizar librerías especializadas de Machine Learning, con el propósito de implementar de forma manual las principales etapas del proceso de entrenamiento, desde el cálculo de las predicciones hasta la actualización de los parámetros del modelo. Este enfoque permitirá comprender con mayor detalle el funcionamiento interno del algoritmo y los elementos que intervienen en su aprendizaje.

Posteriormente, el rendimiento del modelo desarrollado manualmente será comparado con un modelo implementado mediante librerías especializadas como Scikit-learn, utilizando Random Forest como técnica de clasificación. La comparación permitirá analizar las diferencias entre ambos enfoques en términos de desempeño predictivo y evaluar las ventajas de utilizar algoritmos y herramientas especializadas frente a una implementación manual. De esta manera, el proyecto busca no solo predecir el sexo de los abulones a partir de sus características físicas, sino también analizar cómo distintas técnicas de Machine Learning influyen en la capacidad de clasificación del modelo.

II. FUENTE DE DATOS

La fuente de datos utilizada fue obtenida del repositorio de Machine Learning de UCI y contiene 4,177 registros correspondientes a distintas observaciones de abulones. De acuerdo con la documentación, el conjunto original incluía valores nulos, sin embargo, estos fueron eliminados antes de su publicación. Asimismo, los atributos continuos fueron escalados mediante la división de sus valores por un factor de 200, con el propósito de normalizar sus rangos. [3] La siguiente figura muestra los atributos y clase disponibles en el conjunto de datos, los cuales incluyen características físicas relacionadas con las dimensiones, el peso y el sexo de los abulones.

A. Análisis exploratorio de datos

El análisis exploratorio comenzó con asegurar de la calidad general del conjunto de datos, verificando la presencia de

TABLE I
DESCRIPCIÓN DE LOS ATRIBUTOS DEL CONJUNTO DE DATOS

Nombre	Tipo de dato	Medida	Descripción
Sex	Nominal		Sexo del abulón, pueden ser machos (M), hembras (F) o infantes (I)
Length	Continuo	mm	Longitud máxima de la concha
Diameter	Continuo	mm	Diámetro perpendicular a la longitud
Height	Continuo	mm	Altura del abulón
Whole weight	Continuo	gramos	Peso completo del abulón
Shucked weight	Continuo	gramos	Peso de la carne del abulón
Viscera weight	Continuo	gramos	Peso de las vísceras del abulón después de sangrar
Shell weight	Continuo	gramos	Peso de la concha del abulón después de secarse
Rings	Entero		Número de anillos del abulón, si se le suma +1.5 se obtiene un aproximado de su edad

valores nulos y registros duplicados. Posteriormente, se analizó la relación entre las distintas variables asociadas al peso del abulón. Como primer enfoque, se evaluó la relación entre el peso total (*Whole weight*) y la suma del peso de la carne (*Shucked weight*), las vísceras (*Viscera weight*) y la concha (*Shell weight*). Únicamente 9 registros (0.21%) presentaron una coincidencia exacta entre estas cantidades, mientras que en el 99.78% restante se observó alguna diferencia.

Para analizar este comportamiento con mayor detalle, se calculó una nueva variable definida como la diferencia entre el peso total y la suma de los tres pesos parciales. Asimismo, se obtuvo la diferencia porcentual con respecto al peso total, lo que permitió comparar las diferencias independientemente del tamaño de cada ejemplar. La estadística descriptiva mostró una diferencia porcentual promedio de 5.34% y una desviación estándar de 11.4%, lo que indica una dispersión considerable entre los registros. Los valores observados se extendieron desde un máximo de 33% hasta un mínimo de -417.06%.

Las diferencias negativas requieren especial atención, ya que indican que la suma del peso de la carne, las vísceras y la concha supera el peso total registrado para el mismo abulón. El caso más extremo, correspondiente a -417.06%, representa una diferencia considerable entre estas mediciones. Esto podría estar relacionado con el procedimiento de medición o registro de información de los datos, sin embargo, con la información disponible no es posible determinar directamente su causa. Por esta razón, estos registros fueron analizados por separado antes de tomar una decisión sobre su permanencia en el conjunto de datos.

En total, se identificaron 154 instancias con diferencias porcentuales negativas. Para estudiar su magnitud, estas observaciones se agruparon en los intervalos de 0–5%, 5–10%, 10–25% y > 25%. Se encontró que el 72.72% de los casos se concentró en diferencias menores al 10%, mientras que el porcentaje restante presentó discrepancias superiores, llegando

en los casos más extremos hasta 417.06%.

Como siguiente paso, se analizó la distribución de la variable objetivo *Sex*, con el propósito de identificar un posible desbalance entre las clases que pudiera afectar el entrenamiento y la evaluación del modelo. Para ello, se calculó la frecuencia y el porcentaje correspondiente a cada uno de los valores de clase: *Male* (M), *Female* (F) e *Infant* (I).

TABLE II
DISTRIBUCIÓN DE LOS VALORES DE LA CASE SEX

Valor de Sex	Conteo	Porcentaje
Female	1528	36.58%
Infant	1342	32.12%
Male	1307	31.30%

Como se observa en la Tabla II, la distribución de las clases es relativamente equilibrada. La categoría *Female* representa el 36.58% de los registros, seguida de *Infant* con 32.12% y *Male* con 31.30%. Aunque existen pequeñas diferencias entre las proporciones, ninguna clase presenta una cantidad significativamente mayor respecto a las demás. Por esta razón, el conjunto de datos no muestra un des balance de clases considerable que requiera mayor atención.

Posteriormente, se analizaron las estadísticas descriptivas de las columnas numéricas. En la variable de altura, *Height*, se encontró un valor mínimo de 0, debido a que una altura igual o inferior a cero no representa una medida físicamente válida para un abulón, se verificó la presencia de valores menores o iguales a cero en todas las variables numéricas. Como resultado, se encontró únicamente dos registros con esta característica, ambos correspondientes a *Height*, lo que representa aproximadamente el 0.04% del conjunto de datos.

El análisis descriptivo de *Height* también mostró que la altura promedio fue de aproximadamente 0.13 mm, el valor máximo alcanzó 1.13 mm, mientras que el promedio del diámetro fue de 0.4 mm y su valor máximo 0.65 mm. Esta diferencia entre las medias y valores máximos sugirió la posible presencia de valores extremos, por lo que se consideró necesario complementar las estadísticas descriptivas con representaciones gráficas que permitieran observar las distribuciones de las variables y determinar si estos registros se alejaban considerablemente del comportamiento general de los datos.

Se utilizaron diagramas de dispersión para analizar la relación entre distintos atributos físicos e identificar posibles valores atípicos o comportamientos inconsistentes entre las variables. A partir de estas visualizaciones se encontraron los siguientes hallazgos.

En la relación entre altura (*Height*) y longitud (*Length*), la mayoría de los valores de altura se concentraron entre 0 y 0.4, mientras que únicamente dos observaciones superaron el valor de 0.5. Estas instancias se alejaron considerablemente de la distribución general y representaron aproximadamente el 0.04% del conjunto de datos, por lo que fueron identificadas como posibles valores atípicos.

Al comparar la longitud (*Length*) con el diámetro (*Diameter*), se observó una relación lineal entre ambas variables. Sin embargo, se identificó una observación en la que el diámetro era superior a la longitud registrada. Considerando que la longitud representa el tamaño máximo de la concha, esto resulta inconsistente con la definición de ambas variables y representa una restricción física que debe considerarse durante el proceso de limpieza de los datos.

Por otro lado, la relación entre el diámetro (*Diameter*) y el número de anillos (*Rings*) presentó una dispersión notable. Es decir que para valores similares de diámetro se encontraron diferentes cantidades de anillos, lo que sugiere que el tamaño de la concha por sí solo no mantiene una relación lineal alta con esta característica.

Finalmente, se observó una tendencia aproximadamente lineal entre varias de las características físicas analizadas. No obstante, las relaciones entre longitud y peso total (*Length* vs. *Whole weight*), así como entre diámetro y peso total (*Diameter* vs. *Whole weight*), mostraron un comportamiento diferente. En estos casos, el peso parece incrementarse a una tasa mayor conforme aumentan las dimensiones del abulón, generando una relación no lineal.

Estos resultados sirven como criterio para evaluar posteriormente el tratamiento de posibles valores atípicos durante el preprocesamiento de los datos.

B. Transformación de datos

A partir de los resultados obtenidos durante el análisis exploratorio de datos, se decidió eliminar aquellos registros que presentaban valores atípicos o inconsistencias físicas en las variables de altura, diámetro y peso debido a que representaban un pequeño porcentaje del conjunto de datos. Los criterios de eliminación fueron definidos con base en las observaciones realizadas previamente y el desglose de las condiciones aplicadas y la cantidad de registros eliminados se presenta en la siguiente tabla.

TABLE III
REGISTROS ELIMINADOS CON BASE EN EL EDA


Condición	Valores eliminados
Altura ≥ 0	2
Altura ≥ 0.5	2
Diámetro > longitud	1
Diferencia negativa de peso porcentual $> 10\%$	41

Finalmente, se aplicó la técnica de *One-Hot Encoding* sobre la variable objetivo *Sex*. Como resultado, la columna categórica original fue transformada en tres columnas binarias: *Sex_M*, *Sex_I* y *Sex_F*, correspondientes a las clases *Male*, *Infant* y *Female*, respectivamente. Cada observación queda representada mediante valores de 0 y 1, donde el valor 1 indica

la clase a la que pertenece el abulón y las columnas restantes toman el valor 0.

C. Análisis de correlación

Fig. 1. Análisis de correlación entre variables



En la Figura 1 se observa una correlación positiva fuerte entre la mayoría de las variables numéricas relacionadas con las dimensiones y el peso del abulón, con coeficientes que se encuentran aproximadamente entre 0.84 y 0.99. Esto indica que estas características tienden a aumentar de manera conjunta, mientras que las diferentes medidas de peso también muestran relaciones superiores a 0.88. Este comportamiento hace sentido ya que un abulón de mayores dimensiones generalmente presenta también un mayor peso. Por otro lado, la variable *Rings* mantiene correlaciones positivas moderadas con las características físicas, lo que indica una relación menos definida que la observada entre las variables de tamaño y peso.

Al analizar la relación entre las características físicas y las variables objetivo *Sex_M* y *Sex_F* presentan correlaciones positivas relativamente bajas con las variables numéricas. En comparación, la categoría *Sex_I* presenta correlaciones negativas relativamente altas con las variables de dimensiones y peso. Esto resulta intuitivo, debido a que los abulones infantiles tienden a presentar menores dimensiones y pesos que los ejemplares adultos y una vez alcanzada una mayor etapa de desarrollo, las características físicas de machos y hembras presentan mayor similitudes, lo que podría dificultar su diferenciación utilizando únicamente estas variables.

D. Carga de datos

Una vez finalizado el análisis exploratorio y aplicadas las transformaciones definidas durante el preprocesamiento, el conjunto de datos original, compuesto por 4,177 instancias, se redujo a 4,131 registros.

En cuanto al número de columnas, el conjunto de datos pasó de 9 a 11. Este incremento se debe a la aplicación de *One-Hot Encoding* sobre la variable categórica *Sex*, la cual fue sustituida por tres columnas binarias: *Sex_M*, *Sex_I* y *Sex_F*. Como resultado, el conjunto de datos final utilizado para las etapas posteriores presenta dimensiones de (4131, 11).

III. MODELO DE REGRESIÓN LOGÍSTICA MANUAL

La regresión logística es un algoritmo de clasificación utilizado para predecir resultados a partir de una o más variables de entrada. A diferencia de la regresión lineal, su objetivo no es estimar un valor continuo, sino calcular la probabilidad de pertenecer a una clase. Para ello, combina los atributos de entrada mediante con una ecuación lineal $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ y transforma este resultado a un valor entre 0 y 1 mediante una función logística. Por su simplicidad, interpretabilidad y bajo costo computacional, resulta adecuada para problemas de clasificación binaria y puede extenderse a problemas multiclase. [4]

A. Ecuación sigmoide

La función utilizada para convertir el valor de z en una probabilidad es la función sigmoide, definida como:

$$z = \frac{1}{1 + e^{-x}} \quad (1)$$

Esta función produce valores dentro del intervalo $[0, 1]$, por lo que su salida puede interpretarse como la probabilidad estimada de que una observación pertenezca a una clase determinada. Para este problema, la sigmoide resulta apropiada porque cada clasificador debe decidir si un abulón pertenece o no a una categoría específica a partir de sus características físicas.

Sin embargo, nuestra variable objetivo contiene tres clases, *Male*, *Female* e *Infant*, es por ello que se utiliza la estrategia *One vs All*. Esta estrategia transforma el problema multiclase en tres problemas binarios independientes: *Male* contra el resto de clases, *Female* contra el resto e *Infant* contra el resto. De esta manera, es posible utilizar regresión logística binaria con una función sigmoide para cada clase y seleccionar posteriormente aquella con la mayor salida. [5]

B. Entropía cruzada

La entropía cruzada binaria (Binary Cross-Entropy), también conocida como log loss, es una función de pérdida utilizada para medir qué tan diferentes son las probabilidades estimadas por un modelo respecto a las clases reales. En regresión logística, la salida de la función sigmoide se encuentra entre 0 y 1 y representa la probabilidad estimada de pertenecer a la clase positiva. La entropía cruzada penaliza con mayor intensidad aquellas predicciones en las que el modelo asigna una probabilidad alta a una clase incorrecta, mientras que produce un error pequeño cuando la probabilidad estimada coincide con la clase real. [6]

La función de la entropía cruzada puede expresarse como:

$$H_{y'}(y) = - \sum_i [y'_i \log(y_i) + (1 - y'_i) \log(1 - y_i)] \quad (2)$$

C. Gradiente descendente

El gradiente descendente es un algoritmo de optimización utilizado para encontrar los valores de los parámetros de un modelo que minimizan una función de costo. Su funcionamiento consiste en calcular el gradiente de dicha función,

es decir, las derivadas parciales que indican cómo cambia el error respecto a cada parámetro, que representan los pesos (w) y el sesgo del modelo (b). Después, los parámetros se actualizan iterativamente en la dirección opuesta al gradiente. La magnitud de cada actualización está controlada por la tasa de aprendizaje (learning rate), cuyo valor debe ser suficientemente pequeño para permitir una convergencia estable, pero no tan pequeño como para hacer demasiado lento el entrenamiento. [7]

Este requiere de una función de costo que indique qué tan alejadas se encuentran las predicciones del modelo respecto a los valores reales, el cual se obtiene a partir de las probabilidades generadas por la función sigmoide y se calcula mediante entropía cruzada. A partir de este valor de pérdida, el gradiente determina cómo cambia el error respecto a los pesos y al sesgo del modelo. [7]

D. Conjuntos de datos

Los conjuntos de entrenamiento (*train*), validación (*validation*) y prueba (*test*) permiten desarrollar y evaluar un modelo de Machine Learning de forma más confiable. El conjunto de entrenamiento se utiliza para que el modelo aprenda los patrones y ajuste sus parámetros, el conjunto de validación permite evaluar su comportamiento durante el desarrollo y detectar problemas como el sobreajuste, finalmente, el conjunto de prueba se reserva para medir el rendimiento final del modelo con datos que no fueron utilizados durante el entrenamiento ni la validación. De esta manera, la separación de los datos ayuda a estimar qué tan bien puede generalizar el modelo ante nuevas observaciones.

Para entrenar y probar el modelo se utilizaron las siguientes proporciones para cada uno de los conjuntos.

TABLE IV
TAMAÑO DE CADA CONJUNTO

Conjunto	Cantidad de instancias	Porcentaje
Train	2889	69.94%
Validation	619	14.98%
Test	623	15.08%

E. Funciones del modelo

F. Parámetros

Los parametros utilizados como variables independientes son:

- Length
- Diameter
- Height
- Whole weight
- Shucked weight
- Viscera weight
- Shell weight
- Rings

Mientras que la variable a predecir es Sex, sin embargo como está aplicado one hot encoding se desglosa como:

TABLE V
FUNCIONES UTILIZADAS EN EL MODELO

Nombre	Propósito
sigmoid(z)	Convertir el valor dato por la ecuación lineal en una escala de [0, 1].
binary_cross_entropy(y_true, y_hat)	Calcula el error entre el valor real de la variable Sex contra la predicción que realizó el modelo.
distributed_split(x, y, train_size, val_size, seed)	Mezcla los datos de la variable Sex para que se encuentren distribuidas equitativamente sus clases y se asigna a los conjuntos de train, val y test.
train(x_train, y_train, datasets, epochs, alpha)	Entrena al modelo para identificar si es I, M, F almacena los pesos y sesgo en una lista para evaluar la opción mas probable utilizando la tecnica de one vs all.
predict(x, weights, biases)	Obtiene la predicción de la variable Sex, una vez que el modelo ha sido entrenado.
accuracy(y_true, y_hat)	Calcula la proporción de las clases correctamente predichas
confusion_matrix(y_true, y_hat, class_names)	Calcula la matriz de confusión con el resultado de las predicciones contra los valores reales
logistic_regression_analysis(df, epochs, learning_rate)	Engloba todas las funciones anteriores para realizar una regresión logística

- Sex_I
- Sex_F
- Sex_M

G. hiperparámetros

Los hiperparametros son configuraciones que podemos hacer al modelo antes de comenzar el entrenamiento, una vez comenzado no podemos influir en este. Contamos con dos hiperparametros en este modelo, el numero de epocas (*epochs*) y la tasa de aprendizaje (*learning rate*). Los cuales se definieron con los siguientes valores.

- Epochs = 5000
- Learning rate = 0.001

IV. RESULTADOS OBTENIDOS DEL MODELO MANUAL

La siguiente gráfica muestra el error BCE de los conjuntos de train, val y test a lo largo de las 5000 epocas. Acompañada de la siguiente tabla que muestra a detalle el error BCE de cada conjunto.




TABLE VI
PÉRDIDA BCE POR CONJUNTO

Conjunto	BCE
Train	0.5496%
Validation	0.5500%
Test	0.5539%

La siguiente tabla muestra la exactitud (accuracy) que tuvo cada uno de los conjuntos.

TABLE VII
EXACTITUD POR CONJUNTO DEL MODELO MANUAL

Conjunto	Porcentaje de exactitud
Train	53.82%
Validation	53.63%
Test	52.01%


La siguiente tabla muestra las metricas de precisión, recall y f1 para cada una de las clases del modelo manual para el conjunto de prueba o test.

TABLE VIII
MÉTRICAS DEL MODELO MANUAL

Clase	Precisión	Recall	F-1
Infant	0.62	0.82	0.70
Male	0.47	0.63	0.54
Female	0.51	0.15	0.23

La siguiente figura muestra la matriz de confusión.

Fig. 3. Matriz de confusión para la variable Sex del modelo manual



A. Interpretación de los resultados

En la Figura 2 se observa que, al inicio del entrenamiento, los tres conjuntos presentan una pérdida BCE cercana a 0.69. Conforme avanzan las épocas, la pérdida disminuye de manera

progresiva hasta aproximarse a 0.55. Este comportamiento indica que el proceso de optimización mediante gradiente descendente está ajustando los parámetros del modelo en una dirección que reduce la función de costo.

A partir de aproximadamente las 2000 épocas, la disminución del BCE se vuelve cada vez menor. Además, las curvas correspondientes a entrenamiento, validación y prueba permanecen muy próximas entre sí. Este comportamiento también puede observarse en la Tabla VI, donde las diferencias entre los valores finales de BCE de los tres conjuntos son reducidas.

Por otra parte, la Tabla VII muestra que el conjunto de entrenamiento presenta la mayor exactitud, con 53.82%. Este resultado es esperable, ya que dicho conjunto fue utilizado directamente para estimar los pesos y sesgos del modelo. El conjunto de validación obtiene una exactitud de 53.63%, únicamente 0.19 puntos porcentuales por debajo del entrenamiento, lo que sugiere un comportamiento consistente frente a observaciones no utilizadas para actualizar los parámetros. En cuanto al conjunto de prueba, presenta una exactitud de 52.01%, equivalente a una disminución de 1.81 puntos porcentuales respecto al conjunto de entrenamiento. Aunque este conjunto presenta el menor desempeño, la diferencia continúa siendo relativamente pequeña.

Continuando con la tabla XIII esta muestra los valores de precisión que nos indica que proporción de las observaciones predichas como una clase son realmente de esa clase, recall nos explica que proporción de las observaciones reales de una clase fueron identificadas por el modelo como esa clase y f1 es la media armónica entre estos dos valores por lo que penaliza al modelo si alguna de las métricas de precisión o recall es baja.

- Para la clase infant la precisión indica que de 100 predicciones de infant, el modelo acertó aproximadamente 62, recall nos dice que de 100 ejemplos reales pertenecientes a infant, el modelo detectó 82, y el valor de f1 es de 0.70.
- Para la clase de male, la precisión indica que de 100 predicciones de la clase male acertó aproximadamente 47, recall nos dice que de 100 ejemplos reales de la clase male, el modelo detectó 63 y su valor de f1 es de 0.54
- Finalmente la clase female tuvo el menor desempeño, su precisión nos indica que de 100 predicciones de female que hizo el modelo, acertó cerca de 51, recall nos dice que de 100 ejemplos de la clase female, el modelo detectó 15, por este recall tan bajo su f1 cae a 0.23.

Con esta métrica de f1, podemos ver mejor el desempeño de nuestro modelo, que comparado con accuracy que de las predicciones realizadas para el conjunto de prueba aproximadamente el 52.01% fueron ciertas, con f1 podemos conocer mejor el desempeño para identificar cada clase.

Finalmente, la matriz de confusión muestra que para la clase I, el modelo clasificó correctamente 161 de 198 observaciones, lo que equivale aproximadamente a un 81.31% de aciertos para esta clase. En cambio, para la clase M, se clasificaron correctamente 135 de 229 observaciones, equivalente aproximadamente a 58.95%. Finalmente, la clase F presenta el desempeño

más bajo, ya que solamente 28 de 196 observaciones fueron identificadas correctamente, aproximadamente un 14.29%.

La principal dificultad se observa en la clase F, donde 124 observaciones reales fueron clasificadas como M, mientras que otras 44 fueron clasificadas como I. Asimismo, el modelo predijo la clase F únicamente 64 veces, a pesar de que en el conjunto de prueba existían 196 observaciones pertenecientes a esta clase. Esto indica que el modelo presenta una tendencia a asignar con mayor frecuencia las observaciones a las clases I y M, mientras que tiene mayores dificultades para reconocer correctamente la clase F.

Este comportamiento es consistente con lo observado previamente en la figura 1, donde la matriz de correlación mostró que la correlación para M y F es bastante similar, mientras que para I presentaba una correlación distinta, negativa y más representativa.

V. MEJORA DEL MODELO MANUAL

A. Impacto de los hiperparámetros

El hiperparámetro del número de épocas (epochs) define cuantas iteraciones de entrenamiento se realizará el cálculo del gradiente descendente, mientras mayor sea el número de épocas mejor se ajustarán los pesos de cada variable, sin embargo trae consigo un mayor tiempo de ejecución y posiblemente favorecer un comportamiento de overfitting.

El hiperparámetro de la tasa de aprendizaje (learning rate) controla el tamaño de actualización de los pesos, porque existe el riesgo que el cálculo del gradiente descendente nunca encuentre un punto mínimo si el salto que da es demasiado grande, este salto es representado por la tasa de aprendizaje, donde con un valor pequeño hace el aprendizaje más estable y reduce este riesgo, pero también vuelve el entrenamiento más lento.

Se analizó el efecto individual de cada hiperparámetro en el modelo, con las siguientes configuraciones:

- Para probar el efecto del número de épocas, se seleccionaron los valores de 1000, 3000, 5000, 10000 y se dejó una tasa de aprendizaje fija de 0.01 para que no influya en el resultado.
- Para probar el efecto de la tasa de aprendizaje se seleccionaron los valores de 0.0001, 0.001, 0.01, 0.05, 0.1, 0.5 y se dejó el número de épocas fijo en 3000 para probar el efecto de una tasa pequeña (0.0001) a una tasa grande (0.5).

Se obtuvieron los siguientes resultados, donde se calculó el promedio de F1 de las clases como medida general de exactitud, el valor de pérdida del BCE y el tiempo que tardó el entrenamiento para los hiperparámetros de número de épocas y tasa de aprendizaje

TABLE IX
EFECTO DEL NÚMERO DE ÉPOCAS CON TASA DE APRENDIZAJE FIJA 0.01

Epocas	Promedio de F1	BCE	Tiempo (s)
1000	0.4947	0.539704	0.1803
3000	0.5082	0.534248	0.5320
5000	0.5219	0.532376	0.8715
7000	0.5338	0.531247	1.1284
10000	0.5331	0.530312	1.7331

TABLE X
EFECTO DE LA TASA DE APRENDIZAJE CON NÚMERO DE ÉPOCAS FIJAS 3000

Tasa de aprendizaje	Promedio de F1	BCE	Tiempo (s)
0.0001	0.5283	0.640138	0.3334
0.001	0.4860	0.562674	0.3561
0.01	0.5082	0.534248	0.3583
0.05	0.5354	0.529663	0.2617
0.1	0.5372	0.529287	0.2513
0.5	0.5351	0.529532	0.2660

B. Configuración final

Se observa una tendencia en el hiperparametro del número de epocas a aumentar el promedio de F1, reducir el BCE y aumentar el tiempo de ejecución conforme aumenta este número de epocas, sin embargo a partir de las 7000 epocas, se encuentra una reducción muy pequeña en el promedio de F1, pero el BCE sigue disminuyendo, sin embargo el tiempo de ejecución es 0.6 segundos mayor.

En cuanto a la tasa de aprendizaje, se observa que a partir de un valor de 0.05, realmente no hay una mejora notable en el promedio de F1 o una reducción considerable en el BCE. Sin embargo el valor de 0.1 tiene un mejor resultado que 0.05 y un menor tiempo de ejecución.

Se verificaron estas dos tasas de aprendizaje con el número de 7000 épocas porque este número dio los mejores resultados cuando la tasa de aprendizaje estaba fija, se encontró que la configuración de hiperparametros de 7000 épocas y 0.05 de tasa de aprendizaje. Por ende se escogieron estos hiperparametros.

C. Resultados obtenidos

Los siguientes resultados son obtenidos con los hiperparametros elegidos previamente.

TABLE XI
PÉRDIDA BCE POR CONJUNTO

Conjunto	BCE
Train	0.5234%
Validation	0.5292%
Test	0.5348%

En esta tabla se observa con la configuración final existe una disminución de aproximadamente 3 puntos porcentuales en los 3 conjuntos, comparado con la versión inicial.

TABLE XII
EXACTITUD POR CONJUNTO DEL MODELO MANUAL

Conjunto	Porcentaje de exactitud
Train	56.49%
Validation	54.60%
Test	52.81%

En la siguiente tabla también se observa un pequeño aumento porcentual para cada uno de los conjuntos en la exactitud del modelo con la configuración final, por ejemplo para test hubo un aumento de 0.80% en la exactitud.


TABLE XIII
MÉTRICAS DEL MODELO MANUAL

Clase	Precisión	Recall	F-1
Infant	0.66	0.79	0.71
Male	0.48	0.49	0.49
Female	0.47	0.37	0.41

En esta tabla se reportan las metricas de precisión, recall y el valor de F1, se observa una mejoría de 0.01 en el valor de F1 para la clase infant, para la clase male se redujo el valor de recall de 0.63 a 0.49, lo que también redujo su F1 a 0.49.

La clase de female tuvo un aumento considerable de 0.23 a 0.41 en el valor de F1, esto debido a que también aumentó su valor de recall.

Fig. 4. Matriz de confusión para la variable Sex del modelo manual



Los valores reportados de precisión y recall se pueden observar de forma visual en la matriz de confusión del modelo manual con esta configuración, donde se observa que ahora es capaz de identificar mejor la clase female, sin embargo se equivoca en 2/3 partes, especialmente con la clase M.

D. Conclusión

En conclusión, la regresión logística manual permitió construir un modelo capaz de aprender patrones relacionados

con el sexo de los abulones mediante la función sigmoide, entropía cruzada binaria, gradiente descendente y la estrategia *One vs All*. En su configuración inicial, el modelo presentó un desempeño limitado, con una exactitud de 52.01% en el conjunto de prueba. Estos resultados mostraron que la exactitud no era suficiente para describir el comportamiento del modelo, por lo que las métricas de precisión, recall y F1 permitieron identificar con mayor detalle sus principales dificultades de clasificación para cada clase.

Posteriormente, el análisis individual del número de épocas y la tasa de aprendizaje permitió seleccionar una configuración de 7000 épocas y una tasa de aprendizaje de 0.05, considerando el comportamiento del F1, la pérdida BCE y el tiempo de entrenamiento. Con esta configuración, el BCE disminuyó en los tres conjuntos y la exactitud del conjunto de prueba aumentó de 52.01% a 52.81%. Sin embargo, la principal mejora se observó en la clase *Female*, cuyo F1 aumentó de 0.23 a 0.41 debido principalmente a un incremento en su recall. Por otro lado, el F1 de *Male* disminuyó de 0.54 a 0.49, mientras que *Infant* se mantuvo como la clase con mejor desempeño, alcanzando un F1 de 0.71. Por lo tanto, el ajuste de los hiperparámetros mejoró el comportamiento general del modelo, aunque no produjo una mejora uniforme en todas ellas.

Por lo que, la capacidad predictiva final continúa siendo limitada, particularmente para diferenciar entre las clases *Male* y *Female*. Este comportamiento es consistente con lo observado previamente en el análisis de correlación, donde ambas clases presentaban relaciones similares con las características físicas, mientras que *Infant* mostraba un comportamiento más distintivo.

VI. RANDOM FOREST

Random Forest es un algoritmo de aprendizaje supervisado basado en la combinación de múltiples árboles de decisión y puede utilizarse tanto para problemas de clasificación como de regresión. Durante el entrenamiento, cada árbol se construye utilizando una muestra aleatoria de los datos obtenida. Esto permiten generar árboles diferentes y reducir la dependencia entre sus predicciones. [8]

Sin embargo, el uso de numerosos árboles incrementa el costo computacional y el consumo de memoria. Asimismo, aunque un árbol de decisión individual puede interpretarse fácilmente, un bosque compuesto por una gran cantidad de árboles resulta considerablemente más difícil de interpretar. [8]

A. Conjunto de datos

Para entrenar este modelo se usaron las mismas proporciones de datos, 70% para train, y 15% para validation y test. Sin embargo aquí no se utilizó la función de `distributed_split()`, sino la función `train_test_split()` incluida en la librería de scikit-learn.

B. Modelo


Se utilizó el mismo conjunto de datos previamente transformado para eliminar los valores extremos encontrados durante

el analisis exploratorio de datos, sin embargo no se aplicó one hot encoding a esta técnica al no ser necesario.

El modelo fue construido utilizando la librería de scikit-learn mediante la clase `RandomForestClassifier()`, no se especificó ningún hiperparametro al momento, por lo que funciona con los predefinidos por la librería. Una vez entrenado el modelo se calcularon la exactitud, el error del BCE y la matriz de confusión para evaluar el desempeño de este modelo, obteniendo los siguientes resultados.


La siguiente grafica el BCE final para cada conjunto del modelo de Random Forest.

Fig. 5. Error BCE del modelo de Random Forest



La siguiente figura muestra la matriz de confusión para el conjunto de validación del modelo de Random Forest.

Fig. 6. Matriz de confusión del modelo Random Forest



La siguiente tabla muestra la exactitud (accuracy) por conjunto del modelo de Random Forest.

TABLE XIV
EXACTITUD POR CONJUNTO DEL MODELO RANDOM FOREST

Conjunto	Porcentaje de exactitud
Train	100%
Validation	55.97%
Test	56.15%

Finalmente la siguiente tabla muestra las metricas de precisión, recall y f1 para cada una de las clases del modelo random forest para el conjunto de prueba

TABLE XV
MÉTRICAS DEL MODELO CON RANDOM FOREST

Clase	Precisión	Recall	F-1
Infant	0.69	0.72	0.70
Male	0.44	0.45	0.45
Female	0.41	0.38	0.40

C. Interpretación de los resultados

En la Figura 5 se observa una diferencia considerable entre el error BCE del conjunto de entrenamiento y los conjuntos de validación y prueba. El entrenamiento presenta un BCE de 0.1422, mientras que validación y prueba alcanzan valores de 0.5751 y 0.5615, respectivamente. Esta separación indica un comportamiento de sobreajuste (overfitting), que se caracteriza por que el modelo, en este caso Random Forest, se adapta muy bien a los datos utilizados durante el entrenamiento, pero ese desempeño no se mantiene con observaciones que no fueron utilizadas para construir los árboles.

Este comportamiento también es evidente en la Tabla XIV. El modelo obtiene una exactitud de 100% en entrenamiento, pero solamente 55.97% en validación y 56.15% en prueba. La diferencia de aproximadamente 44 puntos porcentuales entre entrenamiento y los otros conjuntos refuerza la presencia de sobreajuste.

Mientras que en la tabla XV las metricas de precisión, recall y f1 indican que:

- Para la clase infant la precision indica que de 100 predicciones de infant, el modelo acertó aproximadamente 69, recall nos dice que de 100 ejemplos reales pertenecientes a infant, el modelo detectó 72, y el valor de f1 es de 0.70.
- Para la clase de male, la precisión indica que de 100 predicciones de la clase male acertó aproximadamente 44, recall nos dice que de 100 ejemplos reales de la clase male, el modelo detecto 45 y su valor de f1 es de 0.45
- Para la clase female su precision nos indica que de 100 predicciones de female que hizo el modelo, acertó cerca de 41, recall nos dice que de 100 ejemplos de la clase female, el modelo detectó 38 y su f1 es de 0.40.

Se nota que hubo una mejora en cuanto a las metricas obtenidas del modelo manual especificamente en la clase de female, pues su valor de f1 es casi del doble. Sin embargo

este comportamiento que se observa con el BCE y accuracy indican que el modelo está actualmente en el comportamiento de overfitting.

Por otro lado en la figura 6, la clase I es la que presenta el mejor reconocimiento, puesto que se clasifican correctamente 153 de 196 observaciones, aproximadamente un 78.1%. A diferencia de la clase F donde solamente se identifican correctamente 85 de 195 casos, aproximadamente un 43.6%, y una cantidad considerable de ellos, 80 observaciones, son confundidos con la clase M. Para la clase M, se clasifican correctamente 109 de 229 observaciones, aproximadamente un 47.6%, mientras que 83 son clasificadas incorrectamente como F. Esto muestra que el modelo distingue con mayor facilidad a los individuos de la clase I, pero presenta dificultades para separar las clases F y M.

VII. MEJORA DEL MODELO RANDOM FOREST

A. Función de los hiperparametros del modelo

El hiperparametro del número de árboles en el bosque ($n_{\text{estimators}}$) afecta dependiendo si se tiene un valor muy pequeño o muy grande, en general con un valor pequeño el modelo entrena más rápido pero puede generalizar peor, mientras que un valor muy grande puede reducir la variabilidad y ayudar a que el modelo sea más estable pero aumenta el tiempo de ejecución y la memoria. Se espera que a partir de cierto punto un número mayor cause muy poca mejora.

El hiperparametro de la profundidad máxima (max_depth) con un valor pequeño genera arboles simples y un menor riesgo de overfitting, no obstante puede haber un riesgo de underfitting por la poca complejidad del arbol. Mientras que un valor grande causa que los arboles capturen patrones más detallados, y aunque el bosque completo atenúa el riesgo de overfitting no está exento que ocurra.

El hiperparametro de la cantidad mínima de observaciones que debe tener una hoja (min_samples_leaf) con un valor pequeño permite divisiones muy especificas, aumenta la complejidad y el riesgo de tener overfitting. Con un valor grande hace que las decisiones tomen más datos, genera predicciones menos extremas y sensibles al ruido, pero puede perder información útil.

El hiperparametro de parámetros máximos (max_features) es el número de variables que participan en cada árbol además de la variable a predecir. Se utilizan tres valores "sqrt", "log2" y None. "Sqrt" usa aproximadamente la raíz cuadrada de variables, "log2" utiliza el logaritmo en base 2 de variables aproximadamente, pero puede hacer a un arbol más debil individualmente. Finalmente None considera todas las variables en cada división, por lo que cada árbol es capaz de encontrar la mejor separación, pero los vuelve muy parecidos entre si, lo que reduce el beneficio de tener muchos arboles y puede favorecer el sobreajuste.

Para verificar el impacto individual de los hiperparametros se realizarán las siguientes configuraciones, donde el hiperparametro a probar estará cambiando y los hiperparametros restantes se dejaran fijos.

- Para probar el efecto del número máximo de árboles, se seleccionaron los valores de 3, 5, 10, 30, 50, 100 y se dejó una profundidad máxima de 10, una cantidad mínima de observaciones de 10, y los parámetros máximos como "sqrt".
- Para probar el efecto de la profundidad máxima, se seleccionaron los valores de 2, 3, 5, 10, 20, None y se dejó un número máximo de árboles de 100, una cantidad mínima de observaciones de 10, y los parámetros máximos como "sqrt".
- Para probar el efecto del número mínimo de observaciones, se seleccionaron los valores de 2, 3, 5, 10, 15 y se dejó un número máximo de árboles de 100, una profundidad máxima de 10 y los parámetros máximos como "sqrt".
- Para probar el efecto del número máximo de parámetros, se seleccionaron los valores de "sqrt", "log2", None y se dejó un número máximo de árboles de 100, una profundidad máxima de 10 y número mínimo de observaciones de 10.

B. Impacto de los hiperparámetros

Se obtuvieron los siguientes resultados, donde se calculó el promedio de F1 de las clases como medida general de exactitud, el valor de perdida del BCE y el tiempo que tardó el entrenamiento para los hiperparámetros del modelo del random forest.

TABLE XVI
EFECTO DEL NÚMERO MÁXIMO DE LOS ARBOLES CON LOS DEMÁS
HIPERPARAMETROS FIJOS

Número máximo de árboles	Promedio de F1	BCE	Tiempo (s)
3	0.5439	0.557251	0.0451
5	0.5532	0.535801	0.0563
10	0.5421	0.525415	0.0746
30	0.5441	0.517728	0.0951
50	0.5467	0.515701	0.1328
100	0.5536	0.514278	0.2518

Las diferencias entre los resultados del número máximo de arboles son pequeñas y por ello podrían no resultar significativas, asumiendo que los resultados son representativos, se observa una tendencia donde un número pequeño de arboles y un número de arboles dan un resultado muy parecido en su promedio de F1, mientras que el BCE si desciende conforme se aumenta el número de árboles, pero también aumenta considerablemente el tiempo de entrenamiento, es por ello que el número máximo de árboles con los resultados más estables cuando los demás hiperparámetros están fijos, para este caso es aproximadamente 5.

TABLE XVII
EFECTO DE LA PROFUNDIDAD MÁXIMA CON LOS DEMÁS
HIPERPARAMETROS FIJOS

Profundidad máxima	Promedio de F1	BCE	Tiempo (s)
2	0.4252	0.533784	0.2219
3	0.4675	0.526382	0.2408
5	0.5300	0.517428	0.2837
10	0.5536	0.514278	0.2797
20	0.5503	0.515146	0.2622
None	0.5514	0.515122	0.2309

La profundidad máxima muestra una tendencia para aumentar el promedio del F1 conforme más profundida, sin embargo aproximadamente en un nivel de 10, con los demás hiperparámetros fijos se observa que es el mayor valor promedio de F1, del mismo modo con este valor se encuentra el menor BCE, no obstante es de los más tardados en tiempo de entrenamiento.

TABLE XVIII
EFECTO DEL NÚMERO MÍNIMO DE OBSERVACIONES CON LOS DEMÁS
HIPERPARAMETROS FIJOS

Número mínimo de observaciones	Promedio de F1	BCE	Tiempo (s)
2	0.5517	0.515843	0.3227
3	0.5449	0.515395	0.3116
5	0.5524	0.514545	0.3038
10	0.5536	0.514278	0.2593
15	0.5438	0.514704	0.2311
30	0.5417	0.517141	0.2016

En este caso se observa que los valores para el min_samples_leaf es bastante similar con 2 y 10, teniendo unos valores ligeramente superiores el valor de 10, sin embargo el tiempo de entrenamiento nos indica que como el 2 es mayor que el 10 y como vimos el efecto que tenía este hiperparámetro, es que si elegimos un valor pequeño tendremos un árbol que no generalice de buena forma, pudiendo tener overfit.

TABLE XIX
EFECTO DEL NÚMERO MÁXIMO DE PARÁMETROS CON LOS DEMÁS
HIPERPARAMETROS FIJOS

Número máximo de parámetros	Promedio de F1	BCE	Tiempo (s)
sqrt	0.5536	0.514278	0.3144
log2	0.5484	0.515402	0.3629
None	0.5535	0.519392	0.5576

Este caso es similar al anterior, por que se observa que el máximo número de parámetros de sqrt y None, tienen promedios de F1 y valores de BCE similares, pero en tiempo de ejecución y en BCE el valor de None es ligeramente peor que sqrt. Por ende este parámetro resulta el ideal para repartir los parámetros para cada árbol.

C. Configuración final

En base a estas tendencias y resultados encontrados en el efecto individual de los hiperparámetros se determinó la configuración que genera un resultado óptimo es la siguiente:

- max_depth: 10
- max_features: sqrt
- min_samples_leaf: 10
- n_estimators: 5

D. Resultados obtenidos

TABLE XX
PÉRDIDA BCE POR CONJUNTO DEL MODELO RANDOM FOREST

Conjunto	BCE
Train	0.4463%
Validation	0.5351%
Test	0.5544%

Se observa un resultado uniforme entre los conjuntos de test y validation, con un resultado similar, mientras que el conjunto de train tiene un valor cerca de 10 puntos porcentuales menor respecto a estos dos conjuntos, lo que muestra que se redujo la tendencia a overfit porque el resultado original del BCE para train era mucho menor, no obstante, no se eliminó del todo.

TABLE XXI
EXACTITUD POR CONJUNTO DEL MODELO RANDOM FOREST

Conjunto	Porcentaje de exactitud
Train	67.52%
Validation	53.55%
Test	52.58%

En la siguiente tabla se observa que la exactitud de 100% previa para el conjunto de train disminuyó a 67.52%, esto nos brinda evidencia de que el comportamiento de overfit se redujo considerablemente, pero como aún difiere cerca de 14 puntos porcentuales de los conjuntos de validation y test, se podría considerar que aún tiene esta tendencia el modelo, pero en menor medida.

TABLE XXII
MÉTRICAS DEL MODELO RANDOM FOREST

Clase	Precisión	Recall	F-1
Infant	0.70	0.74	0.72
Male	0.45	0.45	0.45
Female	0.42	0.39	0.41

En la tabla se observa un valor similar para F-1 en las clases de male y female, el modelo sigue reconociendo con mayor facilidad a la clase Infant. Los resultados son bastante similares a la primera versión.

Los valores de la matriz de confusión indican que el modelo confunde mucho las clases M y F entre sí, pues sus valores reales son muy similares a cuando el modelo predice lo contrario. Mientras que la clase Infant se observa que es la que mejor predice, pero si llega a haber confusiones entre las otras dos clases.

Fig. 7. Matriz de confusión actualizada del modelo de Random Forest





Fig. 8. Error BCE actualizado del modelo de Random Forest



Esta grafica es una representación visual de la primera tabla de esta sección, donde se observa de forma más visual que el error de BCE para cada conjunto es muy similar.

E. Conclusión

La versión ajustada de Random Forest redujo de manera considerable el sobreajuste observado en la configuración inicial. Con los hiperparámetros max_depth=10, max_features=sqrt, min_samples_leaf=10 y n_estimators=5, la exactitud de entrenamiento disminuyó a 67.52%, mientras que en validación y prueba fue de 53.55% y 52.58%, respectivamente. Asimismo, el BCE pasó de 0.4464 en entrenamiento a 0.5352 en validación y 0.5545 en prueba, aunque todavía existe una diferencia entre los conjuntos, esta es menor que la obtenida con la configuración predeterminada, por lo que la capacidad de generalización del modelo mejoró respecto al comportamiento inicial.

No obstante, el desempeño general permanece limitado, especialmente al distinguir las clases *Female* y *Male*, cuyos valores de F1 fueron de 0.41 y 0.45. En contraste, la clase *Infant* obtuvo el mejor resultado, con un F1 de 0.72 y un recall de 0.74. Por lo tanto, el ajuste de hiperparámetros permitió obtener un modelo más equilibrado y menos dependiente de los datos de entrenamiento, sin embargo, aún sería necesario explorar variables adicionales o configuraciones más amplias para mejorar la separación entre las clases *Female* y *Male*.

VIII. CONCLUSIÓN

El desarrollo del proyecto permitió abordar la clasificación del sexo de los abulones a partir de sus características físicas mediante un proceso completo de Machine Learning. El análisis exploratorio permitió identificar valores atípicos e inconsistencias en las variables de altura, diámetro y pesos, por lo que el conjunto de datos se redujo de 4,177 a 4,131 observaciones. Además, se comprobó que las clases *Female*, *Infant* y *Male* presentaban una distribución relativamente equilibrada. Sin embargo, el análisis de correlación mostró que las variables de tamaño y peso se relacionan fuertemente entre sí, pero presentan comportamientos similares para las clases *Male* y *Female*, lo cual dificulta su diferenciación.

El modelo de regresión logística manual obtuvo exactitudes cercanas al 52–54% en los diferentes conjuntos, mostrando un comportamiento estable, aunque con limitaciones para clasificar especialmente la clase *Female*. Por otro lado, el modelo Random Forest inicial alcanzó una exactitud cercana al 56% en validación y prueba, pero presentó un sobreajuste considerable al obtener 100% en entrenamiento. Posteriormente, el ajuste de hiperparámetros permitió reducir esta diferencia, obteniendo una exactitud de 67.52% en entrenamiento, 53.55% en validación y 52.58% en prueba. Aunque esta configuración redujo el sobreajuste, no generó una mejora importante en el desempeño sobre datos no vistos.

Al analizar las métricas por clase, ambos modelos identificaron con mayor facilidad a los abulones *Infant*. La regresión logística manual obtuvo para esta clase una precisión de 0.66, un recall de 0.79 y un F1 de 0.71, mientras que Random Forest alcanzó valores de 0.70, 0.74 y 0.72, respectivamente. Para la clase *Male*, el modelo manual obtuvo precisión, recall y F1 de 0.48, 0.49 y 0.49, resultados ligeramente superiores a los de Random Forest, con 0.45 en las tres métricas. En contraste, ambos modelos presentaron dificultades con la clase *Female*, aunque Random Forest obtuvo una precisión de 0.42, recall de 0.39 y F1 de 0.41, estos resultados fueron similares a los de la regresión logística manual, con valores de 0.47, 0.37 y 0.41. Por lo tanto, las métricas confirman que las características físicas disponibles permiten reconocer mejor a los individuos *Infant*, pero no contienen suficiente información para diferenciar de forma confiable entre abulones machos y hembras.

REFERENCES

- [1] Basto Cuevas, A. M. (s.f.). Identificación del sexo y del desarrollo gonadal en el abulón rojo *Haliotis rufescens*, en cautiverio. Red De Repositorios Latinoamericanos.

<https://repositorioslatinoamericanos.uchile.cl/items/b56c316f-8874-4eb9-ae4e-e963412d1909>

- [2] Abulón – HISOUR Arte Cultura Historia. (s.f.). <https://www.hisour.com/es/data/abalone/>
- [3] Abalone - UCI Machine Learning Repository. (1995, November). UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/1/abalone>.
- [4] Amazon Web Services. (s.f.). ¿Qué es la regresión logística? Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/logistic-regression/>
- [5] OneVsRestClassifier. (s.f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.multiclass.OneVsRestClassifier.html>
- [6] log_loss. (s.f.). Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.log_loss.html
- [7] Donges, N. (2024, August). Gradient Descent in Machine Learning: A Basic Introduction. Built In. <https://builtin.com/data-science/gradient-descent>
- [8] RandomForestClassifier. (s.f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>