

Identificar el sexo de abulones mediante regresión logística.

Yael Charles Marin

A01711111

Tecnológico de Monterrey Campús Querétaro

Inteligencia artificial avanzada para la ciencia de datos

Grupo 601

Abstract—Este trabajo trata sobre la clasificación del sexo de abulones utilizando las características físicas de longitud, diámetro, altura, diferentes medidas de peso y número de anillos. Se realizó un análisis exploratorio de datos, transformación, análisis de correlación, desarrollo de modelos y evaluación de desempeño. Durante el preprocesamiento se identificaron y eliminaron observaciones extremas o físicamente inconsistentes, reduciendo el conjunto original de 4,177 a 4,131 registros. El análisis de correlación mostró relaciones fuertes entre las variables físicas, mientras que la clase Infant presentó un comportamiento más notorio en comparación con las clases Male y Female. Posteriormente, se implementó manualmente un modelo de regresión logística utilizando la estrategia One-vs-All, donde se obtuvo exactitudes de 53.82%, 53.63% y 52.01% en los conjuntos de entrenamiento, validación y prueba, respectivamente. También se evaluó un modelo Random Forest implementado con scikit-learn, el cual alcanzó 100% de exactitud en entrenamiento y aproximadamente 56% en validación y prueba. Ambos modelos mostraron una mayor capacidad para identificar la clase Infant, mientras que distinguir entre Male y Female representó la principal dificultad de clasificación. Esto sugiere que las características físicas disponibles permiten identificar con mayor claridad los abulones en etapas tempranas de su desarrollo, pero presentan una capacidad limitada para separar de forma efectiva a los abulones machos y hembras.

Index Terms—Abulón, clasificación, regresión logística, sigmoide, entropía cruzada, gradiente descendiente, algoritmo manual, random forest, evaluación de resultados.

I. INTRODUCTION

Los abulones son moluscos gasterópodos marinos pertenecientes al género *Haliotis*, caracterizados por poseer una sola concha de forma aplanada y un cuerpo blando con un pie muscular que les permite adherirse a superficies rocosas. Su carne es considerada un producto de alto valor comercial y alimenticio en lugares como China o Japón, aunque también en gastronomías como la Estadounidense y Mexicana. [1]

La identificación del sexo de los abulones es relevante principalmente para el manejo reproductivo y la crianza selectiva en sistemas de cultivo. Los abulones presentan sexos separados, es decir, cada individuo es macho o hembra, y su reproducción ocurre mediante la liberación de espermatozoides y óvulos al agua. Sin embargo, determinar el sexo puede ser complicado en individuos jóvenes o que todavía no han desarrollado suficientemente sus órganos reproductores. Esta dificultad representa una oportunidad para utilizar técnicas de

Machine Learning que permitan estimar el sexo a partir de características físicas fácilmente medibles del abulón. [2]

Este proyecto tiene como objetivo utilizar atributos físicos de los abulones, como sus medidas corporales y peso, para predecir su sexo mediante técnicas de clasificación implementadas en Python. Para ello, se desarrollará inicialmente un modelo de regresión logística sin utilizar librerías especializadas de Machine Learning, con el propósito de implementar de forma manual las principales etapas del proceso de entrenamiento, desde el cálculo de las predicciones hasta la actualización de los parámetros del modelo. Este enfoque permitirá comprender con mayor detalle el funcionamiento interno del algoritmo y los elementos que intervienen en su aprendizaje.

Posteriormente, el rendimiento del modelo desarrollado manualmente será comparado con un modelo implementado mediante librerías especializadas como Scikit-learn, utilizando Random Forest como técnica de clasificación. La comparación permitirá analizar las diferencias entre ambos enfoques en términos de desempeño predictivo y evaluar las ventajas de utilizar algoritmos y herramientas especializadas frente a una implementación manual. De esta manera, el proyecto busca no solo predecir el sexo de los abulones a partir de sus características físicas, sino también analizar cómo distintas técnicas de Machine Learning influyen en la capacidad de clasificación del modelo.

II. FUENTE DE DATOS

La fuente de datos utilizada fue obtenida del repositorio de Machine Learning de UCI y contiene 4,177 registros correspondientes a distintas observaciones de abulones. De acuerdo con la documentación, el conjunto original incluía valores nulos, sin embargo, estos fueron eliminados antes de su publicación. Asimismo, los atributos continuos fueron escalados mediante la división de sus valores por un factor de 200, con el propósito de normalizar sus rangos. [3] La siguiente figura muestra los atributos y clase disponibles en el conjunto de datos, los cuales incluyen características físicas relacionadas con las dimensiones, el peso y el sexo de los abulones.

A. Análisis exploratorio de datos

El análisis exploratorio comenzó con asegurar de la calidad general del conjunto de datos, verificando la presencia de

TABLE I
DESCRIPCIÓN DE LOS ATRIBUTOS DEL CONJUNTO DE DATOS

Nombre	Tipo de dato	Medida	Descripción
Sex	Nominal		Sexo del abulón, pueden ser machos (M), hembras (F) o infantes (I)
Length	Continuo	mm	Longitud máxima de la concha
Diameter	Continuo	mm	Diámetro perpendicular a la longitud
Height	Continuo	mm	Altura del abulón
Whole weight	Continuo	gramos	Peso completo del abulón
Shucked weight	Continuo	gramos	Peso de la carne del abulón
Viscera weight	Continuo	gramos	Peso de las vísceras del abulón después de sangrar
Shell weight	Continuo	gramos	Peso de la concha del abulón después de secarse
Rings	Entero		Número de anillos del abulón, si se le suma +1.5 se obtiene un aproximado de su edad

valores nulos y registros duplicados. Posteriormente, se analizó la relación entre las distintas variables asociadas al peso del abulón. Como primer enfoque, se evaluó la relación entre el peso total (*Whole weight*) y la suma del peso de la carne (*Shucked weight*), las vísceras (*Viscera weight*) y la concha (*Shell weight*). Únicamente 9 registros (0.21%) presentaron una coincidencia exacta entre estas cantidades, mientras que en el 99.78% restante se observó alguna diferencia.

Para analizar este comportamiento con mayor detalle, se calculó una nueva variable definida como la diferencia entre el peso total y la suma de los tres pesos parciales. Asimismo, se obtuvo la diferencia porcentual con respecto al peso total, lo que permitió comparar las diferencias independientemente del tamaño de cada ejemplar. La estadística descriptiva mostró una diferencia porcentual promedio de 5.34% y una desviación estándar de 11.4%, lo que indica una dispersión considerable entre los registros. Los valores observados se extendieron desde un máximo de 33% hasta un mínimo de -417.06%.

Las diferencias negativas requieren especial atención, ya que indican que la suma del peso de la carne, las vísceras y la concha supera el peso total registrado para el mismo abulón. El caso más extremo, correspondiente a -417.06%, representa una diferencia considerable entre estas mediciones. Esto podría estar relacionado con el procedimiento de medición o registro de información de los datos, sin embargo, con la información disponible no es posible determinar directamente su causa. Por esta razón, estos registros fueron analizados por separado antes de tomar una decisión sobre su permanencia en el conjunto de datos.

En total, se identificaron 154 instancias con diferencias porcentuales negativas. Para estudiar su magnitud, estas observaciones se agruparon en los intervalos de 0–5%, 5–10%, 10–25% y > 25%. Se encontró que el 72.72% de los casos se concentró en diferencias menores al 10%, mientras que el porcentaje restante presentó discrepancias superiores, llegando

en los casos más extremos hasta 417.06%.

Como siguiente paso, se analizó la distribución de la variable objetivo *Sex*, con el propósito de identificar un posible desbalance entre las clases que pudiera afectar el entrenamiento y la evaluación del modelo. Para ello, se calculó la frecuencia y el porcentaje correspondiente a cada uno de los valores de clase: *Male* (M), *Female* (F) e *Infant* (I).

TABLE II
DISTRIBUCIÓN DE LOS VALORES DE LA CASE SEX

Valor de Sex	Conteo	Porcentaje
Female	1528	36.58%
Infant	1342	32.12%
Male	1307	31.30%

Como se observa en la Tabla II, la distribución de las clases es relativamente equilibrada. La categoría *Female* representa el 36.58% de los registros, seguida de *Infant* con 32.12% y *Male* con 31.30%. Aunque existen pequeñas diferencias entre las proporciones, ninguna clase presenta una cantidad significativamente mayor respecto a las demás. Por esta razón, el conjunto de datos no muestra un des balance de clases considerable que requiera mayor atención.

Posteriormente, se analizaron las estadísticas descriptivas de las columnas numéricas. En la variable de altura, *Height*, se encontró un valor mínimo de 0, debido a que una altura igual o inferior a cero no representa una medida físicamente válida para un abulón, se verificó la presencia de valores menores o iguales a cero en todas las variables numéricas. Como resultado, se encontró únicamente dos registros con esta característica, ambos correspondientes a *Height*, lo que representa aproximadamente el 0.04% del conjunto de datos.

El análisis descriptivo de *Height* también mostró que la altura promedio fue de aproximadamente 0.13 mm, el valor máximo alcanzó 1.13 mm, mientras que el promedio del diámetro fue de 0.4 mm y su valor máximo 0.65 mm. Esta diferencia entre las medias y valores máximos sugirió la posible presencia de valores extremos, por lo que se consideró necesario complementar las estadísticas descriptivas con representaciones gráficas que permitieran observar las distribuciones de las variables y determinar si estos registros se alejaban considerablemente del comportamiento general de los datos.

Se utilizaron diagramas de dispersión para analizar la relación entre distintos atributos físicos e identificar posibles valores atípicos o comportamientos inconsistentes entre las variables. A partir de estas visualizaciones se encontraron los siguientes hallazgos.

En la relación entre altura (*Height*) y longitud (*Length*), la mayoría de los valores de altura se concentraron entre 0 y 0.4, mientras que únicamente dos observaciones superaron el valor de 0.5. Estas instancias se alejaron considerablemente de la distribución general y representaron aproximadamente el 0.04% del conjunto de datos, por lo que fueron identificadas como posibles valores atípicos.

Al comparar la longitud (*Length*) con el diámetro (*Diameter*), se observó una relación lineal entre ambas variables. Sin embargo, se identificó una observación en la que el diámetro era superior a la longitud registrada. Considerando que la longitud representa el tamaño máximo de la concha, esto resulta inconsistente con la definición de ambas variables y representa una restricción física que debe considerarse durante el proceso de limpieza de los datos.

Por otro lado, la relación entre el diámetro (*Diameter*) y el número de anillos (*Rings*) presentó una dispersión notable. Es decir que para valores similares de diámetro se encontraron diferentes cantidades de anillos, lo que sugiere que el tamaño de la concha por sí solo no mantiene una relación lineal alta con esta característica.

Finalmente, se observó una tendencia aproximadamente lineal entre varias de las características físicas analizadas. No obstante, las relaciones entre longitud y peso total (*Length* vs. *Whole weight*), así como entre diámetro y peso total (*Diameter* vs. *Whole weight*), mostraron un comportamiento diferente. En estos casos, el peso parece incrementarse a una tasa mayor conforme aumentan las dimensiones del abulón, generando una relación no lineal.

Estos resultados sirven como criterio para evaluar posteriormente el tratamiento de posibles valores atípicos durante el preprocesamiento de los datos.

B. Transformación de datos

A partir de los resultados obtenidos durante el análisis exploratorio de datos, se decidió eliminar aquellos registros que presentaban valores atípicos o inconsistencias físicas en las variables de altura, diámetro y peso debido a que representaban un pequeño porcentaje del conjunto de datos. Los criterios de eliminación fueron definidos con base en las observaciones realizadas previamente y el desglose de las condiciones aplicadas y la cantidad de registros eliminados se presenta en la siguiente tabla.

TABLE III
REGISTROS ELIMINADOS CON BASE EN EL EDA


Condición	Valores eliminados
Altura ≥ 0	2
Altura ≥ 0.5	2
Diámetro > longitud	1
Diferencia negativa de peso porcentual > 10%	41

Finalmente, se aplicó la técnica de *One-Hot Encoding* sobre la variable objetivo *Sex*. Como resultado, la columna categórica original fue transformada en tres columnas binarias: *Sex_M*, *Sex_I* y *Sex_F*, correspondientes a las clases *Male*, *Infant* y *Female*, respectivamente. Cada observación queda representada mediante valores de 0 y 1, donde el valor 1 indica

la clase a la que pertenece el abulón y las columnas restantes toman el valor 0.

C. Análisis de correlación

Fig. 1. Análisis de correlación entre variables



En la Figura 1 se observa una correlación positiva fuerte entre la mayoría de las variables numéricas relacionadas con las dimensiones y el peso del abulón, con coeficientes que se encuentran aproximadamente entre 0.84 y 0.99. Esto indica que estas características tienden a aumentar de manera conjunta, mientras que las diferentes medidas de peso también muestran relaciones superiores a 0.88. Este comportamiento hace sentido ya que un abulón de mayores dimensiones generalmente presenta también un mayor peso. Por otro lado, la variable *Rings* mantiene correlaciones positivas moderadas con las características físicas, lo que indica una relación menos definida que la observada entre las variables de tamaño y peso.

Al analizar la relación entre las características físicas y las variables objetivo *Sex_M* y *Sex_F* presentan correlaciones positivas relativamente bajas con las variables numéricas. En comparación, la categoría *Sex_I* presenta correlaciones negativas relativamente altas con las variables de dimensiones y peso. Esto resulta intuitivo, debido a que los abulones infantiles tienden a presentar menores dimensiones y pesos que los ejemplares adultos y una vez alcanzada una mayor etapa de desarrollo, las características físicas de machos y hembras presentan mayor similitudes, lo que podría dificultar su diferenciación utilizando únicamente estas variables.

D. Carga de datos

Una vez finalizado el análisis exploratorio y aplicadas las transformaciones definidas durante el preprocesamiento, el conjunto de datos original, compuesto por 4,177 instancias, se redujo a 4,131 registros.

En cuanto al número de columnas, el conjunto de datos pasó de 9 a 11. Este incremento se debe a la aplicación de *One-Hot Encoding* sobre la variable categórica *Sex*, la cual fue sustituida por tres columnas binarias: *Sex_M*, *Sex_I* y *Sex_F*. Como resultado, el conjunto de datos final utilizado para las etapas posteriores presenta dimensiones de (4131, 11).

III. MODELO DE REGRESIÓN LOGÍSTICA MANUAL

La regresión logística es un algoritmo de clasificación utilizado para predecir resultados a partir de una o más variables de entrada. A diferencia de la regresión lineal, su objetivo no es estimar un valor continuo, sino calcular la probabilidad de pertenecer a una clase. Para ello, combina los atributos de entrada mediante con una ecuación lineal $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ y transforma este resultado a un valor entre 0 y 1 mediante una función logística. Por su simplicidad, interpretabilidad y bajo costo computacional, resulta adecuada para problemas de clasificación binaria y puede extenderse a problemas multiclase. [4]

A. Ecuación sigmoide

La función utilizada para convertir el valor de z en una probabilidad es la función sigmoide, definida como:

$$z = \frac{1}{1 + e^{-x}} \quad (1)$$

Esta función produce valores dentro del intervalo $[0, 1]$, por lo que su salida puede interpretarse como la probabilidad estimada de que una observación pertenezca a una clase determinada. Para este problema, la sigmoide resulta apropiada porque cada clasificador debe decidir si un abulón pertenece o no a una categoría específica a partir de sus características físicas.

Sin embargo, nuestra variable objetivo contiene tres clases, *Male*, *Female* e *Infant*, es por ello que se utiliza la estrategia *One vs All*. Esta estrategia transforma el problema multiclase en tres problemas binarios independientes: *Male* contra el resto de clases, *Female* contra el resto e *Infant* contra el resto. De esta manera, es posible utilizar regresión logística binaria con una función sigmoide para cada clase y seleccionar posteriormente aquella con la mayor salida. [5]

B. Entropía cruzada

La entropía cruzada binaria (Binary Cross-Entropy), también conocida como log loss, es una función de pérdida utilizada para medir qué tan diferentes son las probabilidades estimadas por un modelo respecto a las clases reales. En regresión logística, la salida de la función sigmoide se encuentra entre 0 y 1 y representa la probabilidad estimada de pertenecer a la clase positiva. La entropía cruzada penaliza con mayor intensidad aquellas predicciones en las que el modelo asigna una probabilidad alta a una clase incorrecta, mientras que produce un error pequeño cuando la probabilidad estimada coincide con la clase real. [6]

La función de la entropía cruzada puede expresarse como:

$$H_{y'}(y) = - \sum_i [y'_i \log(y_i) + (1 - y'_i) \log(1 - y_i)] \quad (2)$$

C. Gradiente descendente

El gradiente descendente es un algoritmo de optimización utilizado para encontrar los valores de los parámetros de un modelo que minimizan una función de costo. Su funcionamiento consiste en calcular el gradiente de dicha función,

es decir, las derivadas parciales que indican cómo cambia el error respecto a cada parámetro, que representan los pesos (w) y el sesgo del modelo (b). Después, los parámetros se actualizan iterativamente en la dirección opuesta al gradiente. La magnitud de cada actualización está controlada por la tasa de aprendizaje (learning rate), cuyo valor debe ser suficientemente pequeño para permitir una convergencia estable, pero no tan pequeño como para hacer demasiado lento el entrenamiento. [7]

Este requiere de una función de costo que indique qué tan alejadas se encuentran las predicciones del modelo respecto a los valores reales, el cual se obtiene a partir de las probabilidades generadas por la función sigmoide y se calcula mediante entropía cruzada. A partir de este valor de pérdida, el gradiente determina cómo cambia el error respecto a los pesos y al sesgo del modelo. [7]

D. Conjuntos de datos

Los conjuntos de entrenamiento (*train*), validación (*validation*) y prueba (*test*) permiten desarrollar y evaluar un modelo de Machine Learning de forma más confiable. El conjunto de entrenamiento se utiliza para que el modelo aprenda los patrones y ajuste sus parámetros, el conjunto de validación permite evaluar su comportamiento durante el desarrollo y detectar problemas como el sobreajuste, finalmente, el conjunto de prueba se reserva para medir el rendimiento final del modelo con datos que no fueron utilizados durante el entrenamiento ni la validación. De esta manera, la separación de los datos ayuda a estimar qué tan bien puede generalizar el modelo ante nuevas observaciones.

Para entrenar y probar el modelo se utilizaron las siguientes proporciones para cada uno de los conjuntos.

TABLE IV
TAMAÑO DE CADA CONJUNTO

Conjunto	Cantidad de instancias	Porcentaje
Train	2889	69.94%
Validation	619	14.98%
Test	623	15.08%

E. Funciones del modelo

F. Parámetros

Los parametros utilizados como variables independientes son:

- Length
- Diameter
- Height
- Whole weight
- Shucked weight
- Viscera weight
- Shell weight
- Rings

Mientras que la variable a predecir es Sex, sin embargo como está aplicado one hot encoding se desglosa como:

TABLE V
FUNCIONES UTILIZADAS EN EL MODELO

Nombre	Propósito
sigmoid(z)	Convertir el valor dato por la ecuación lineal en una escala de [0, 1].
binary_cross_entropy(y_true, y_hat)	Calcula el error entre el valor real de la variable Sex contra la predicción que realizó el modelo.
distributed_split(x, y, train_size, val_size, seed)	Mezcla los datos de la variable Sex para que se encuentren distribuidas equitativamente sus clases y se asigna a los conjuntos de train, val y test.
train(x_train, y_train, datasets, epochs, alpha)	Entrena al modelo para identificar si es I, M, F almacena los pesos y sesgo en una lista para evaluar la opción mas probable utilizando la tecnica de one vs all.
predict(x, weights, biases)	Obtiene la predicción de la variable Sex, una vez que el modelo ha sido entrenado.
accuracy(y_true, y_hat)	Calcula la proporción de las clases correctamente predichas
confusion_matrix(y_true, y_hat, class_names)	Calcula la matriz de confusión con el resultado de las predicciones contra los valores reales
logistic_regression_analysis(df, epochs, learning_rate)	Engloba todas las funciones anteriores para realizar una regresión logística

- Sex_I
- Sex_F
- Sex_M

G. hiperparámetros

Los hiperparametros son configuraciones que podemos hacer al modelo antes de comenzar el entrenamiento, una vez comenzado no podemos influir en este. Contamos con dos hiperparametros en este modelo, el numero de epocas (*epochs*) y la taza de aprendizaje (*learning rate*). Los cuales se definieron con los siguientes valores.

- Epochs = 5000
- Learning rate = 0.001

IV. RESULTADOS OBTENIDOS DEL MODELO MANUAL

La siguiente gráfica muestra el error BCE de los conjuntos de train, val y test a lo largo de las 5000 epocas. Acompañada de la siguiente tabla que muestra a detalle el error BCE de cada conjunto.




TABLE VI
PÉRDIDA BCE POR CONJUNTO

Conjunto	BCE
Train	0.5496%
Validation	0.5500%
Test	0.5539%


La siguiente tabla muestra la exactitud (accuracy) que tuvo cada uno de los conjuntos.

TABLE VII
EXACTITUD POR CONJUNTO DEL MODELO MANUAL

Conjunto	Porcentaje de exactitud
Train	53.82%
Validation	53.63%
Test	52.01%

La siguiente figura muestra la matriz de confusión.

Fig. 3. Matriz de confusión para la variable Sex del modelo manual



A. Interpretación de los resultados

En la Figura 2 se observa que, al inicio del entrenamiento, los tres conjuntos presentan una pérdida BCE cercana a 0.69. Conforme avanzan las épocas, la pérdida disminuye de manera progresiva hasta aproximarse a 0.55. Este comportamiento indica que el proceso de optimización mediante gradiente descendente está ajustando los parámetros del modelo en una dirección que reduce la función de costo.

A partir de aproximadamente las 2000 épocas, la disminución del BCE se vuelve cada vez menor. Además, las curvas correspondientes a entrenamiento, validación y prueba permanecen muy próximas entre sí. Este comportamiento también puede observarse en la Tabla VI, donde las diferencias entre los valores finales de BCE de los tres conjuntos son reducidas.

Por otra parte, la Tabla X muestra que el conjunto de entrenamiento presenta la mayor exactitud, con 53.82%. Este resultado es esperable, ya que dicho conjunto fue utilizado directamente para estimar los pesos y sesgos del modelo. El conjunto de validación obtiene una exactitud de 53.63%, únicamente 0.19 puntos porcentuales por debajo del entrenamiento, lo que sugiere un comportamiento consistente frente a observaciones no utilizadas para actualizar los parámetros. En cuanto al conjunto de prueba, presenta una exactitud de 52.01%, equivalente a una disminución de 1.81 puntos porcentuales respecto al conjunto de entrenamiento. Aunque este conjunto presenta el menor desempeño, la diferencia continúa siendo relativamente pequeña.

Finalmente, la matriz de confusión muestra que para la clase I, el modelo clasificó correctamente 161 de 198 observaciones, lo que equivale aproximadamente a un 81.31% de aciertos para esta clase. En cambio, para la clase M, se clasificaron correctamente 135 de 229 observaciones, equivalente aproximadamente a 58.95%. Finalmente, la clase F presenta el desempeño más bajo, ya que solamente 28 de 196 observaciones fueron identificadas correctamente, aproximadamente un 14.29%.

La principal dificultad se observa en la clase F, donde 124 observaciones reales fueron clasificadas como M, mientras que otras 44 fueron clasificadas como I. Asimismo, el modelo predijo la clase F únicamente 64 veces, a pesar de que en el conjunto de prueba existían 196 observaciones pertenecientes a esta clase. Esto indica que el modelo presenta una tendencia a asignar con mayor frecuencia las observaciones a las clases I y M, mientras que tiene mayores dificultades para reconocer correctamente la clase F.

Este comportamiento es consistente con lo observado previamente en la figura 1, donde la matriz de correlación mostró que la correlación para M y F es bastante similar, mientras que para I presentaba una correlación distinta, negativa y más representativa.

B. Conclusión

En conclusión, los resultados obtenidos muestran que la capacidad predictiva del modelo es limitada para este problema de clasificación. La matriz de confusión permite observar que esta limitación no afecta de la misma manera a las tres clases. La categoría *Infant* obtuvo el mejor desempeño, con aproximadamente 81.31% de sus observaciones correctamente clasificadas, mientras que *Male* alcanzó aproximadamente 58.95% y *Female* únicamente 14.29%. En particular, una gran proporción de las hembras fue clasificada incorrectamente como macho, lo que demuestra una dificultad considerable para diferenciar estas dos categorías a partir de las variables utilizadas.

Este comportamiento es consistente con los resultados obtenidos durante el análisis de correlación. Las características relacionadas con las dimensiones y pesos presentan un comportamiento más distintivo para los abulones infantiles, mientras que las categorías *Male* y *Female* muestran relaciones similares con estas variables. Por lo tanto, una posible explicación del desempeño del modelo es que, una vez que los abulones

alcanzan una mayor etapa de desarrollo, las características físicas disponibles en el conjunto de datos no proporcionan suficiente separación lineal para distinguir de manera efectiva entre machos y hembras.

V. MEJORA DEL MODELO MANUAL

Para presentar una mejora al modelo manual, se decidió cambiar los hiperparámetros para encontrar el par que mejores resultados presentara. El criterio para determinar los mejores hiperparámetros es el siguiente: aquel cuyo valor de accuracy sea mayor y en caso de empate que su valor de pérdida BCE sea menor.

Dicho esto para el modelo manual se definió la siguiente matriz con diferentes hiperparámetros para las épocas de entrenamiento y para la tasa de aprendizaje.

TABLE VIII
HIPERPARAMETROS DE NUMERO DE EPOCAS Y TAZA DE APRENDIZAJE

Hiperparametro	Valores
Epocas	1000, 3000, 5000, 10000
Taza de aprendizaje	0.0001, 0.001, 0.01, 0.05

Se entrenó el modelo y verificó con el conjunto de validación para encontrar los hiperparámetros que satisficieran estas dos condiciones, una vez hecho esto se encontró que con 3000 épocas y una tasa de aprendizaje de 0.05, los resultados fueron mejores.

Una vez encontrados se utilizó el conjunto de prueba, obteniendo los siguientes resultados para cada conjunto.

TABLE IX
VALOR DEL BCE Y ACCURACY POR CONJUNTO

Conjunto	BCE	Accuracy
Train	0.5246	56.04%
Validation	0.5296	54.44 %
Test	0.5353	52.01%

Analizando más a fondo estos resultados podemos notar que la exactitud para los conjuntos de entrenamiento y validación subió un poco respecto al modelo con los hiperparámetros iniciales, sin embargo la exactitud de entrenamiento se mantuvo igual.

No obstante si representa una mejora en el número de épocas de entrenamiento y como la tasa de aprendizaje es menor, tardará menos tiempo en llegar a un resultado mejor.

VI. RANDOM FOREST

Random Forest es un algoritmo de aprendizaje supervisado basado en la combinación de múltiples árboles de decisión y puede utilizarse tanto para problemas de clasificación como de regresión. Durante el entrenamiento, cada árbol se construye utilizando una muestra aleatoria de los datos obtenida. Esto permiten generar árboles diferentes y reducir la dependencia entre sus predicciones. [8]

Sin embargo, el uso de numerosos árboles incrementa el costo computacional y el consumo de memoria. Asimismo,

aunque un árbol de decisión individual puede interpretarse fácilmente, un bosque compuesto por una gran cantidad de árboles resulta considerablemente más difícil de interpretar. [8]

A. Conjunto de datos


Para entrenar este modelo se usaron las mismas proporciones de datos, 70% para train, y 15% para validation y test. Sin embargo aquí no se utilizó la función de `distributed_split()`, sino la función `train_test_split()` incluida en la librería de `scikit-learn`.

B. Modelo

Se utilizó el mismo conjunto de datos previamente transformado para eliminar los valores extremos encontrados durante el análisis exploratorio de datos, sin embargo no se aplicó `one hot encoding` a esta técnica al no ser necesario.


El modelo fue construido utilizando la librería de `scikit-learn` mediante la clase `RandomForestClassifier()`, no se especificó ningún hiperparámetro al momento, por lo que funciona con los predefinidos por la librería. Una vez entrenado el modelo se calcularon la exactitud, el error del BCE y la matriz de confusión para evaluar el desempeño de este modelo, obteniendo los siguientes resultados.

La siguiente grafica el BCE final para cada conjunto del modelo de Random Forest.



La siguiente figura muestra la matriz de confusión para el conjunto de validación del modelo de Random Forest.

Fig. 5. Matriz de confusión del modelo Random Forest



Finalmente la siguiente tabla muestra la exactitud (accuracy) por conjunto del modelo de Random Forest.

TABLE X
EXACTITUD POR CONJUNTO DEL MODELO RANDOM FOREST

Conjunto	Porcentaje de exactitud
Train	100%
Validation	55.97%
Test	56.15%

C. Interpretación de los resultados

En la Figura 4 se observa una diferencia considerable entre el error BCE del conjunto de entrenamiento y los conjuntos de validación y prueba. El entrenamiento presenta un BCE de 0.1422, mientras que validación y prueba alcanzan valores de 0.5751 y 0.5615, respectivamente. Esta separación indica un comportamiento de sobreajuste (`overfitting`), que se caracteriza por que el modelo, en este caso Random Forest, se adapta muy bien a los datos utilizados durante el entrenamiento, pero ese desempeño no se mantiene con observaciones que no fueron utilizadas para construir los árboles.

Este comportamiento también es evidente en la Tabla X. El modelo obtiene una exactitud de 100% en entrenamiento, pero solamente 55.97% en validación y 56.15% en prueba. La diferencia de aproximadamente 44 puntos porcentuales entre entrenamiento y los otros conjuntos refuerza la presencia de sobreajuste.

Por otro lado en la matriz de confusión, la clase I es la que presenta el mejor reconocimiento, puesto que se clasifican correctamente 153 de 196 observaciones, aproximadamente un 78.1%. A diferencia de la clase F donde solamente se identifican correctamente 85 de 195 casos, aproximadamente un 43.6%, y una cantidad considerable de ellos, 80 observaciones,

son confundidos con la clase M. Para la clase M, se clasifican correctamente 109 de 229 observaciones, aproximadamente un 47.6%, mientras que 83 son clasificadas incorrectamente como F. Esto muestra que el modelo distingue con mayor facilidad a los individuos de la clase I, pero presenta dificultades para separar las clases F y M.

D. Conclusión

La implementación de Random Forest permitió evaluar una alternativa basada en árboles de decisión frente al modelo desarrollado previamente. A pesar de utilizar los datos transformados durante el análisis exploratorio y mantener proporciones equivalentes para entrenamiento, validación y prueba, el modelo presentó una diferencia muy marcada entre su desempeño con el conjunto de entrenamiento con datos no vistos, debido a que se obtuvo una exactitud del 100% en entrenamiento, en contraste con valores cercanos al 56% en validación y prueba, junto con la diferencia observada en el BCE, demuestra que el modelo aprendió en exceso las características particulares del conjunto de entrenamiento.

Por otra parte, la matriz de confusión muestra que el modelo logra distinguir con mayor facilidad a la clase I, mientras que presenta mayores dificultades para diferenciar entre las clases F y M, las cuales son confundidas frecuentemente entre sí. Debido a que el modelo fue entrenado con los parámetros predeterminados de `RandomForestClassifier()`, existe margen para mejorar su capacidad de generalización mediante el ajuste de hiperparámetros que controlen la complejidad de los árboles y reduzcan el sobreajuste.

VII. MEJORA DEL MODELO RANDOM FOREST

El modelo inicial de random forest no se definieron hiperparámetros, esto representaba un gran problema por que comparando la exactitud de cada uno de los conjuntos se identificó un claro problema de overfitting.

Para solucionar esto se definieron los siguientes:

TABLE XI
HIPERPARAMETROS DEL MODELO DE RANDOM FOREST

Hiperparámetro	Valores
<code>n_estimators</code>	5, 8, 10, 15
<code>max_depth</code>	2, 3, 5, 10, None
<code>max_features</code>	1, 2, 4
<code>min_samples_leaf</code>	sqrt, log2, None

Para identificar la mejor agrupación de hiperparámetros se utilizó el mismo criterio de aquellos que presentaran la mayor exactitud y el menor BCE, con base en esto se identificó que la combinación de:

- `max_depth`: 5
- `max_features`: log2
- `min_samples_leaf`: 1
- `n_estimators`: 10

La siguiente tabla muestra los resultados finales de cada conjunto con esta configuración de hiperparámetros.

Se observa que ahora el modelo no está memorizando todos los patrones en el conjunto de entrenamiento, porque

TABLE XII
VALOR DEL BCE Y ACCURACY POR CONJUNTO

Conjunto	BCE	Accuracy
Train	0.4894	64.03%
Validation	0.5075	55.48 %
Test	0.5131	55.97%

se limitaron los niveles de profundidad del árbol y sus nodos. Ahora muestra una exactitud del 64.03% para el conjunto de entrenamiento y un BCE más cercano a los dos conjuntos restantes. Sin embargo en el valor de exactitud del conjunto de prueba se observa una pequeña disminución respecto al modelo sin hiperparámetros.

No obstante esto es preferible porque al no memorizar los patrones del dataset hará que el modelo pueda actuar mejor con datos que no conoce.

VIII. CONCLUSIÓN

El desarrollo del proyecto permitió abordar el problema de clasificación del sexo de los abulones mediante un proceso de Machine Learning, comenzando por el análisis exploratorio de datos y su procesamiento. Durante esta etapa se identificaron inconsistencias y valores atípicos relacionados con la altura, el diámetro y las diferentes mediciones de peso, por lo que se tomó la decisión de eliminar estas instancias, pasando de 4,177 a 4,131 observaciones. Asimismo, se comprobó que las clases *Female*, *Infant* y *Male* se encontraban equilibradas, evitando que un desbalance significativo afectara los resultados.

El análisis de correlación permitió observar una de las principales dificultades del problema y es que las variables relacionadas con dimensiones y pesos presentan correlaciones muy fuertes entre sí, mientras que su relación con las clases *Male* y *Female* es relativamente baja y similar entre sí. Por otro lado, la clase *Infant* presenta un comportamiento con correlaciones negativas y más fuerte que las otras dos clases. Este patrón se reflejó en ambos modelos. Primero con el modelo manual el error se redujo de forma estable durante las 5000 épocas y se mantuvo similar entre entrenamiento, validación y prueba, la exactitud permaneció alrededor del 52–54%, mostrando especialmente dificultades para identificar la clase F, mientras que la clase I alcanzó el mejor desempeño.

Posteriormente, la implementación de Random Forest mediante `RandomForestClassifier()` de scikit-learn permitió utilizar un modelo capaz de representar relaciones más complejas. Con este modelo se incrementó ligeramente la exactitud sobre datos no vistos, obteniendo aproximadamente 56% en validación y prueba, además de presentar una mejora en identificar la clase F respecto al modelo manual. Sin embargo, como alcanzó una exactitud del 100% en entrenamiento y un BCE considerablemente menor en este conjunto, demuestra que se tiene un sobreajuste.

En conclusión, aunque Random Forest ofrece una mejora moderada frente a la regresión logística manual, los resultados muestran que para mejorar la exactitud del modelo se requiere no solo ajustar los hiperparámetros del modelo para controlar el sobreajuste o encontrar otros modelos que no sean tan

complejos para este tipo de problema, sino también evaluar si las variables disponibles contienen suficiente información para diferenciar de manera confiable las tres clases.

REFERENCES

- [1] Basto Cuevas, A. M. (s.f.). Identificación del sexo y del desarrollo gonadal en el abulón rojo *Haliotis rufescens*, en cautiverio. Red De Repositorios Latinoamericanos. <https://repositorioslatinoamericanos.uchile.cl/items/b56c316f-8874-4eb9-ae4e-e963412d1909>
- [2] Abulón – HISOUR Arte Cultura Historia. (s.f.). <https://www.hisour.com/es/data/abalone/>
- [3] Abalone - UCI Machine Learning Repository. (1995, November). UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/1/abalone>.
- [4] Amazon Web Services. (s.f.). ¿Qué es la regresión logística? Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/logistic-regression/>
- [5] OneVsRestClassifier. (s.f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.multiclass.OneVsRestClassifier.html>
- [6] log_loss. (s.f.). Scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.log_loss.html
- [7] Donges, N. (2024, August). Gradient Descent in Machine Learning: A Basic Introduction. Built In. <https://builtin.com/data-science/gradient-descent>
- [8] RandomForestClassifier. (s.f.). Scikit-learn. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>